



UNIVERSIDAD TÉCNICA PARTICULAR DE LOJA

La Universidad Católica de Loja

FACULTAD DE INGENIERIAS Y ARQUITECTURA

MAESTRÍA EN INTELIGENCIA ARTIFICIAL APLICADA

Uso de EDA y fuentes de datos para un caso particular

Becerra Estrella, Mauricio Xavier

LOJA
2027

Uso de EDA y fuentes de datos para un caso particular

1.1 Información del Data Set utilizado

Título del Cuaderno: Exploratory Data Analysis: Traffic Volume

Link: <https://www.kaggle.com/code/yorkyong/exploratory-data-analysis-traffic-volume>

Razones de la elección:

Relevancia Sectorial: La gestión del tráfico y la movilidad es un pilar fundamental en la planificación de ciudades inteligentes (Smart Cities) y la optimización de servicios públicos.

Variedad de Información: Contiene datos de tiempo (DateTime), categóricos (clima, días festivos) y numéricos (temperatura, volumen de tráfico), lo que permite aplicar técnicas de EDA tanto univariantes como multivariantes.

Nombre del DataSet: Metro_Interstate_Traffic_Volume_train.csv

Link:

https://raw.githubusercontent.com/mauricioxavier22/eda_data/refs/heads/main/Metro_Interstate_Traffic_Volume_train.csv

Descripción: Registra el volumen de tráfico por hora en la autopista I-94 en dirección Oeste, junto con variables climáticas y días festivos desde 2012 hasta 2018.

Tamaño: filas 40255, columnas 14

Principales Atributos:

Atributos Principales (Diccionario de Datos)

Atributo	Tipo de Dato	Descripción
holiday	Categórico (Texto)	Indica si el día es festivo (ej. Thanksgiving, Christmas) o un día común.
temp	Numérico (Continuo)	Temperatura media de la región en grados Kelvin.
rain_1h	Numérico (Continuo)	Cantidad de lluvia ocurrida en la última hora (en mm).
snow_1h	Numérico (Continuo)	Cantidad de nieve ocurrida en la última hora (en mm).
clouds_all	Numérico (Discreto)	Porcentaje de nubosidad (0 a 100%).
weather_main	Categórico (Texto)	Categoría principal del clima (ej. Clear, Clouds, Rain, Snow).

weather_description	Categorico (Texto)	Descripción detallada del clima (ej. light rain, scattered clouds).
date_time	Temporal (DateTime)	Fecha y hora del registro (Formato: AAAA-MM-DD HH:MM:SS).
traffic_volume	Numérico (Continuo)	Volumen de tráfico registrado por hora (valores enteros).

Lenguaje: Python

Librerías usadas:

Librería	Propósito Principal en el EDA
pandas	Manipulación y estructura de datos. Utilizada para cargar el archivo CSV, inspeccionar los tipos de datos con info, extraer estadísticas descriptivas con describe.
numpy	Operaciones matemáticas. Manejo de matrices de datos y tratamiento de valores nulos o transformaciones numéricas.
matplotlib.pyplot	Visualización de datos base. Creación de los gráficos, personalización de ejes, títulos y estilos generales.
seaborn	Visualización estadística. Generación de gráficos, mapas de calor, boxplots y diagramas de dispersión.

1.2 Análisis Exploratorio de los Datos

Paso1: entendiendo los datos

Inspección inicial y estructural de los datos utilizando métodos como: .head(), .shape, .info(), .dtypes, carga del dataset y reconocimiento de los tipos de datos.

Paso 2: Preparación de los datos

Tratamiento de Fechas: Conversión de date_time, eliminación de campos no necesarios, nuevos atributos generados (año, mes, día), eliminación de filas duplicadas, remoción de datos de temperatura erróneos.

Paso 3: Comprensión de funciones

Uso de graficos para evaluar la distribución del volumen de tráfico, medición de la frecuencia de tipos de clima, distirbucion de datos categóricos (lluvia, nieve, nubosidad).

Paso 4: Relacionamiento

Uso de gráficos para relacionar variables (temperatura vs volumen de trafico), correlaciones entre (Temperatura, Lluvia_1h, Nieve_1h, Nubosidad, Volumen_Trafico), volumen de trafico en el tiempo.

Paso 5: Preguntas acerca de los datos

Se detecto un decrecimiento en el volumen de trafico entre julio y diciembre de 2016, se intentó determinar la causa mediante el análisis de los datos mediante graficos de temperatura por mes, bloxplot de volumen de trafico y clima, condiciones climaticas, días festivos.

1.3 Importancia y objetivos de la aplicación de EDA.

Permite limpiar los datos y eliminar registros duplicados, aumentando la precisión de los resultados. Facilita la identificación de Patrones no visibles a simple vista y realizar una reducción de dimensionalidad, descartando variables redundantes.